Estudo sobre o COVID-19 (09-11/20)

Renan Costa Viana

1. Introdução

A COVID-19 (Corona Vírus Disease 2019) foi, ao mesmo até agora, a doença com maiores impactos da história. Apesar de menos letal que muitas outras, a facilidade com que se espalhava, a alta demografia da sociedade atual e a intensa globalização tornou esse momento fértil para o aparecimento de uma doença assim, tão fértil que antes mesmo de surgir já se falava sobre quando (e não se) um vírus ou bactéria conseguiria gerar uma pandemia (a Doença X).

Conhecendo boa parte dos problemas gerados pela COVID-19 e o necessário isolamento da população (queda de PIB, problemas de educação e sociabilização de jovens, etc), se torna muito importante conhecer as características dos infectados para saber como tratá-los ou prever picos similares.

Para esse relatório foram usadas as bases de pesquisa sobre COVID-19 do IBGE para os meses de setembro a novembro de 2020. De todas as perguntas foram escolhidas estas 14:

- Mês da pesquisa
- Situação do domicílio
- Idade do morador
- Sexo
- Cor ou raça
- Escolaridade
- Na semana passada teve febre?
- Na semana passada teve tosse?
- Na semana passada teve perde de cheiro ou sabor?
- Qual o resultado? (para testes SWAB)
- Algum médico já lhe deu o diagnóstico de diabetes?
- Algum médico já lhe deu o diagnóstico de hipertensão?
- Tipo de trabalho, cargo ou função no seu trabalho principal
- Na semana passada estava em home office?

2. Pipeline de Dados

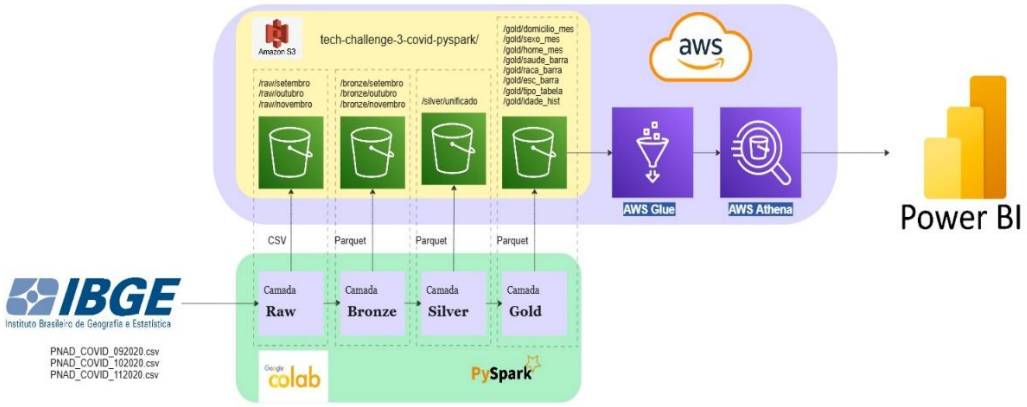

Os dados foram carregados diretamente do site do IBGE a partir de suas URLs no Google Colab, usando o framework do PySpark para lidar com a quantidade massiva de dados. Por código criamos um bucket no AWS S3 e pastas para as camadas medalhão Raw, Bronze, Silver e Gold.

- Na Raw foram colocados os arquivos em seu formato original, csv.
- Na Bronze os arquivos foram convertidos para parquet, para melhorar o processamento.
- Na Silver os arquivos foram unificados em um só parquet, com os dados tratados e as colunas renomeadas.
- Na Gold foram colocados datasets filtrados, um para cada visualização de uso.

As transformações feitas na camada Silver, além da unificação, foram substituídos os códigos nos nomes das colunas pelas perguntas dos formulários do IBGE, assim como os valores numéricos nas colunas para suas respectivas respostas em string (por exemplo, na coluna Sexo, 1 e 2 foram substituídos por Homem e Mulher. Também foram substituídos os valores nulos pela string "Não Aplicável" dado que não podia ser retirada pois as linhas ainda tinham informações importantes (por exemplo, para a coluna Na semana passada estava em home office? as linhas de quem não trabalhava tinham valor nulo, mas ainda assim podia ser pessoas com informações importantes).

Já os datasets da gold filtravam somente os casos Positivos em 8 visualizações diferentes, nomeadas pelas variáveis e tipo dos gráficos escolhidos (por exemplo, esc_barra traz as informações de escolaridade para um gráfico de barras).

Com as camadas criadas e os arquivos carregados na nuvem, foram criados databases e crawlers no AWS Glue para que as informações pudessem

ser usadas no AWS Athena, a forma utilizada para carregá-los no Power BI, onde foram construídas as visualizações.

3. Análise de Dados

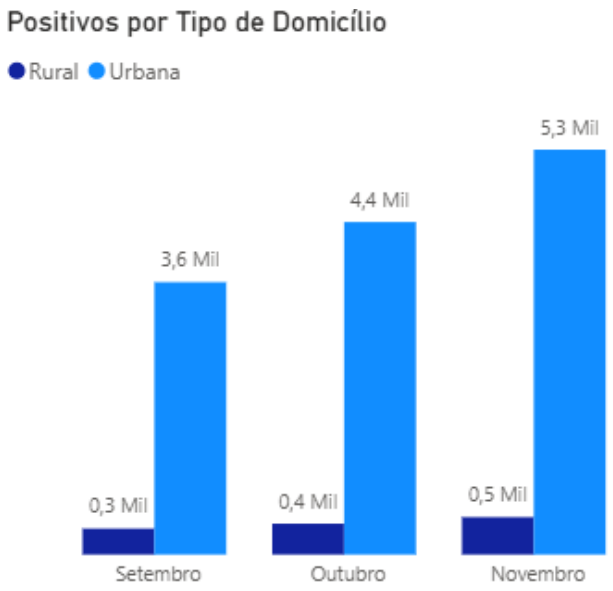

Em nosso primeiro gráfico temos a evolução das casos positivos no SWAB entre os três meses, dividido entre o tipo de domicílio. Podemos ver que dentro da população urbana o número de casos é maior, o que já era esperado por dois fatores: (1) a população em geral maior da áreas urbanas e (2) a facilidade maior de infecção em áreas de alta demografia. Apesar de aumentos nos casos terem sido esperados durante os primeiros meses de pandemia, é válido ressaltar que esse meses coincidem com diversos afrouxamentos de medidas sanitárias e radicalização do discurso contra o isolamento social

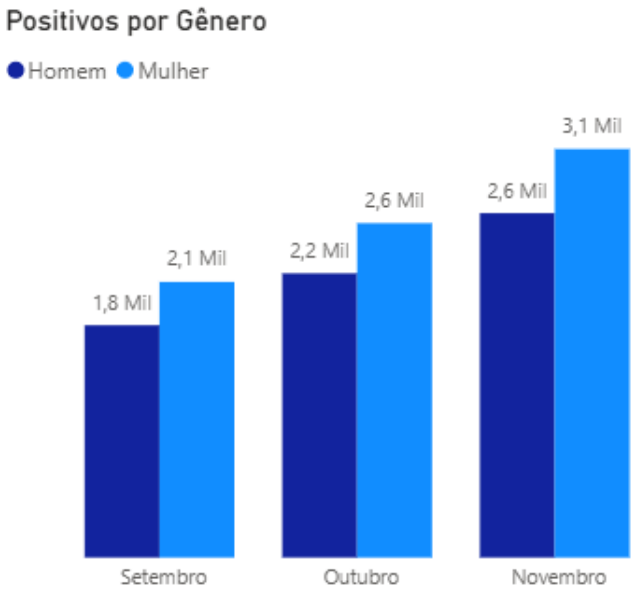

Na divisão de gêneros o resultado surpreende: mulheres superaram os homens. Mesmo que a diferença não seja tanta, ela vai contra a noção de que os homens tendem a se descuidar mais em relação a saúde.

Porém, os tipos de trabalhos que não puderam ser transformados em home office podem ser uma resposta a isso. Boa parte deles eram comumente feito por homens (construção civil, polícia, entregas, etc), mas o setor de saúde foi aquele que mais lidou diretamente com infectados, um setor majoritariamente feminino, principalmente se considerarmos as funções que tem mais contato com os pacientes.

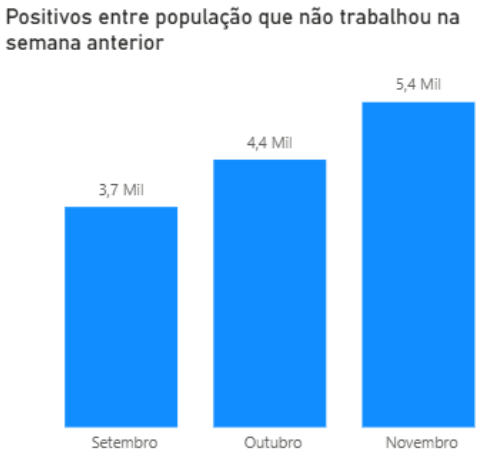

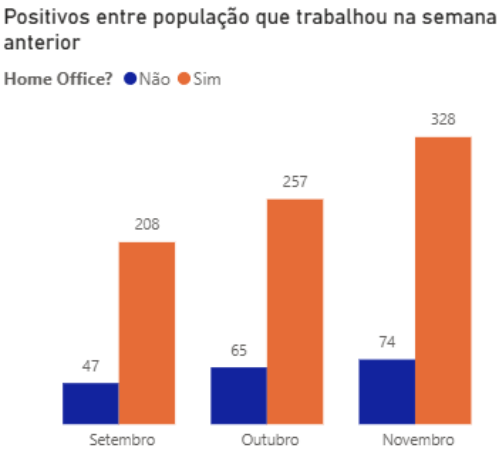

Os números de positivos que trabalharam na semana anterior foram, obviamente, baixos. Dado que o isolamento depois do resultado positivo é de no mínimo 15 dias, dificilmente haveria muita pessoas trabalhando. Porém considerando a gravidade da situação os números ainda são grandes. A maior parte dos positivos que trabalharam foram através do home office, mas ainda há aqueles que eram presenciais, provavelmente trabalhadores liberais ou MEI.

Entre os níveis de escolaridade, o Médio completo supera todos, sendo também o maior entre a população geral. Já os níveis abaixo e acima dele se invertem. Apesar de ainda ser uma minoria, aqueles com Ensino Superior completo ou Pós-graduação tem níveis grandes, proporcionalmente. Isso pode ser explicado por diversos fatores como: (1) boa parte dos empregos no setor de saúde requirirem diploma universitário e (2) pessoas com diploma do ensino superior tendem a receber mais e morarem em bairros mais centrais e com densidade demográfica maior.

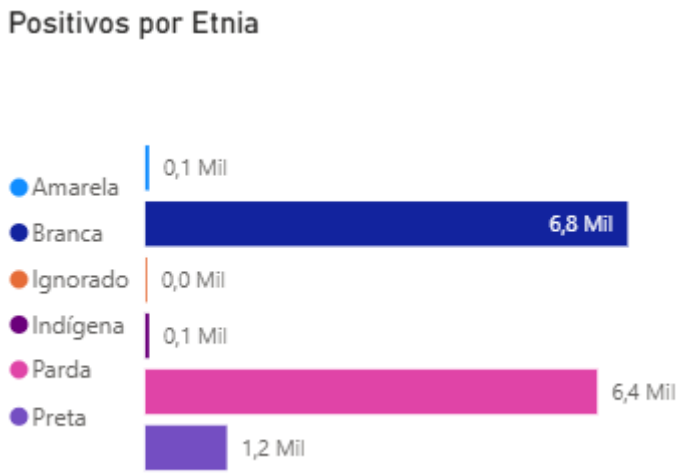

Os casos positivos divididos por etnias seguem de perto as distribuições da população, tendo somente a Branca um pouco díspar, provavelmente relacionado a questão da escolaridade.

A maioria dos positivos nos testes SWAB não tinham comorbidades e/ou sintomas na semana anterior, o que se mostra preocupante, pois dificulta a identificação antecipada dos casos.

Trabalhos com mais positivos

Tipo	Positivos
Outros	831
Prof. saúde sup.	667
Outros nível sup.	662
Prof. saúde méd.	591
Gerente/político	560
Aux. escritório	532
Outros nível méd.	519
Professor (fund/sup)	345
Balconista/vendedor	331
Pedreiro/eletricista	325
Comerciante	319
Doméstico/cozinheiro	305
Secretária/recepção	255
Faxineiro/limpeza	251

Trabalhos com menos positivos

Tipo	Positivos
Motoboy	17
Artista/religioso	24
Aux. agropecuária	24
Cuidador	27
Policial civil	38
Entregador	49
Porteiro/zelador	51
Telemarketing	55
Vendedor ambulante	66
Pedagogo/idiomas	68
Padeiro/açougueiro	74
Artesão/costureiro	117
Cozinheiro/garçom	145
Caminhoneiro	146

Nossa hipótese sobre o gráfico de escolaridade se reforça quando olhamos os tipos de trabalho com mais positivos: profissionais de saúde e com ensino superior tomam a maior parte do ranking.

Enquanto isso do outro lado aqueles com menos positivos os trabalhos que o senso comum diria que são os mais vulneráveis dominam, como motoboys e cozinheiros, que precisavam trabalhar presencialmente. Outras profissões que se destacam são aquelas com pouco contato humano, como auxiliares de agropecuária e telemarketing.

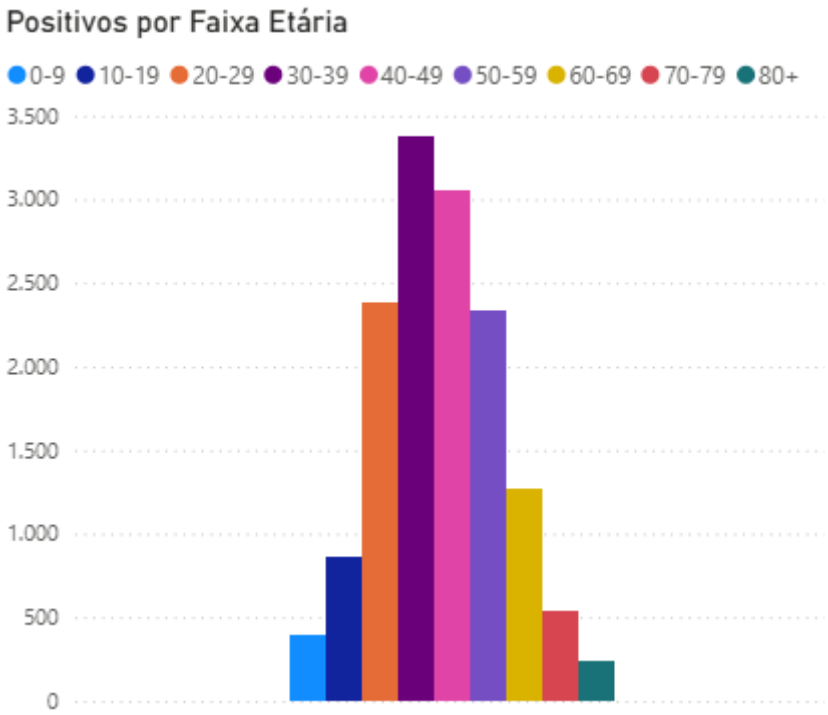

As faixas etárias mais vulneráveis tiveram poucos infectados em comparação com a população geral. Aqueles que foram afetados acima foram nas populações do meio (20-59), os que fazem parte da força de trabalho, continuando as tendências apresentadas em escolaridade e tipos de trabalho.

4. Conclusão

Os cuidados reservados as populações vulneráveis parecem ter tido um grande efeito. Porém isso pode ter deixado as pessoas fora desses grupos confiantes demais em relação ao COVID-19.

Também vemos que o senso comum pouco funciona para identificar as populações mais afetadas. É necessária uma atenção maior as populações de classe média, principalmente urbanas, em regiões de alta demografia.

Por fim, de nada adianta os hospitais se prepararem para os pacientes se os profissionais de saúde se infectarem. São necessárias mais medidas para prevenir isso, tanto para a proteção desses profissionais quanto daqueles tratados por eles.

Com esse panorama geral e o pipeline de dados montado, acreditamos que seja possível o monitoramento das tendências dos casos positivos com relatórios futuros do IBGE, tornando as decisões mais assertivas em relação as populações focais.